五 Yarn

5.1 Yarn 概述

Yarn 是一个资源调度平台，负责为运算程序提供服务器运算资源，相当于一个分布式的操作系统平台，而 MapReduce 等运算程序则相当于运行于操作系统之上的应用程序。

5.2 Yarn 基本架构

YARN 主要由 ResourceManager、NodeManager、ApplicationMaster 和 Container 等组件构成。

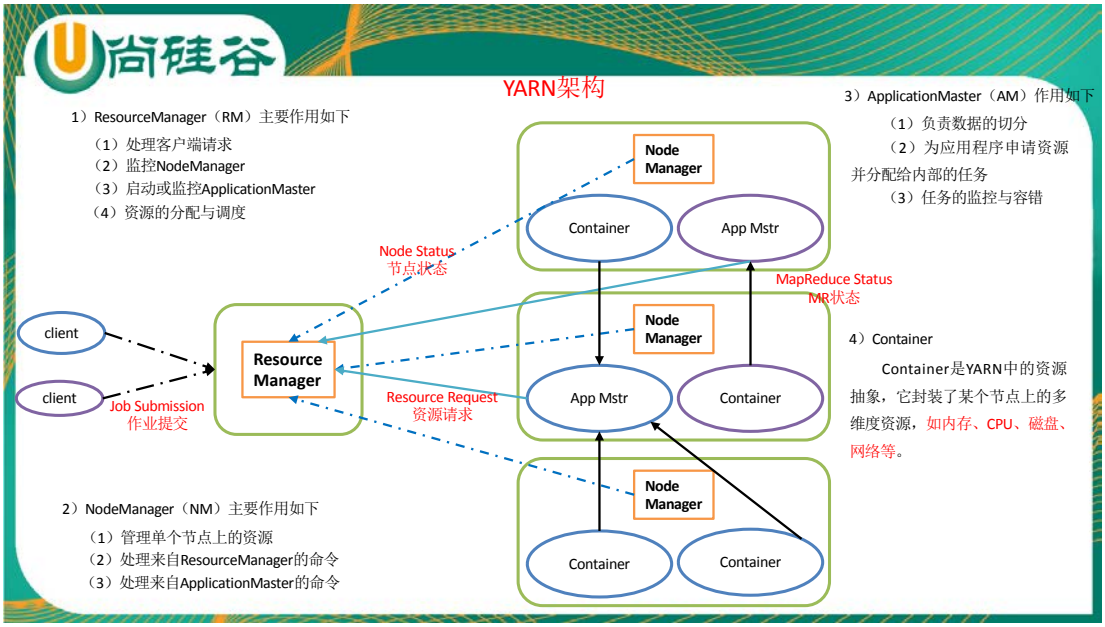

5.3 Yarn 工作机制

1）Yarn 运行机制

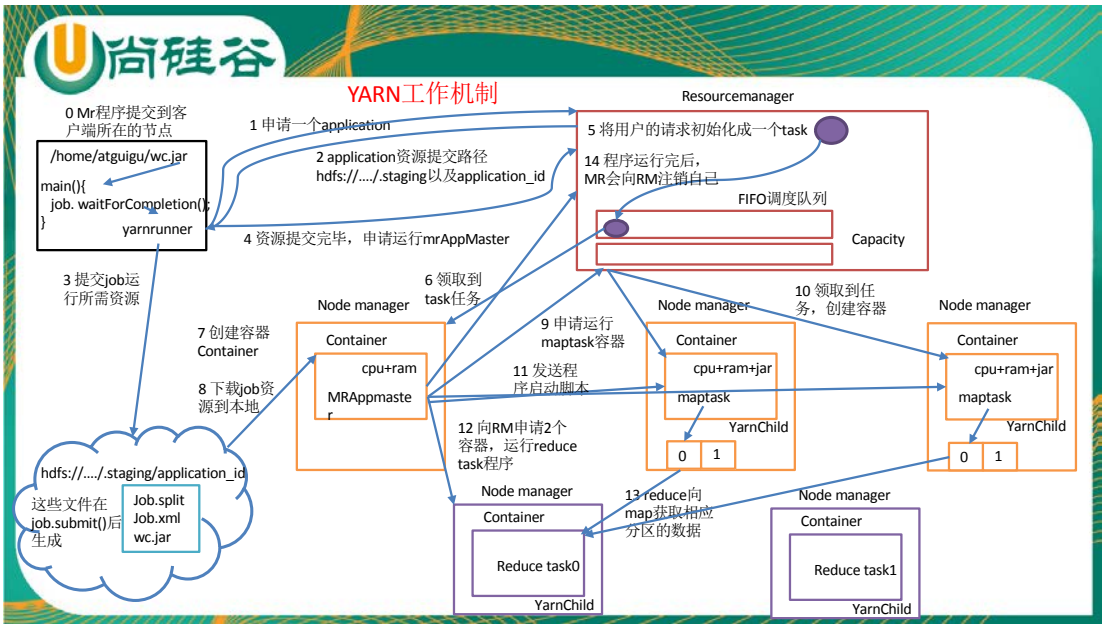

2）工作机制详解

（0）Mr 程序提交到客户端所在的节点。

（1）Yarnrunner 向 Resourcemanager 申请一个 Application。

（2）rm 将该应用程序的资源路径返回给 yarnrunner。

（3）该程序将运行所需资源提交到 HDFS 上。

（4）程序资源提交完毕后，申请运行 mrAppMaster。

（5）RM 将用户的请求初始化成一个 task。

（6）其中一个 NodeManager 领取到 task 任务。

（7）该 NodeManager 创建容器 Container，并产生 MRAppmaster。

（8）Container 从 HDFS 上拷贝资源到本地。

（9）MRAppmaster 向 RM 申请运行 maptask 资源。

（10）RM 将运行 maptask 任务分配给另外两个 NodeManager，另两个 NodeManager 分别领取任务并创建容器。

（11）MR 向两个接收到任务的 NodeManager 发送程序启动脚本，这两个 NodeManager 分别启动 maptask，maptask 对数据分区排序。

（12）MrAppMaster 等待所有 maptask 运行完毕后，向 RM 申请容器，运行 reduce task。

（13）reduce task 向 maptask 获取相应分区的数据。

（14）程序运行完毕后，MR 会向 RM 申请注销自己。

5.4 作业提交全过程

1）作业提交过程之 YARN

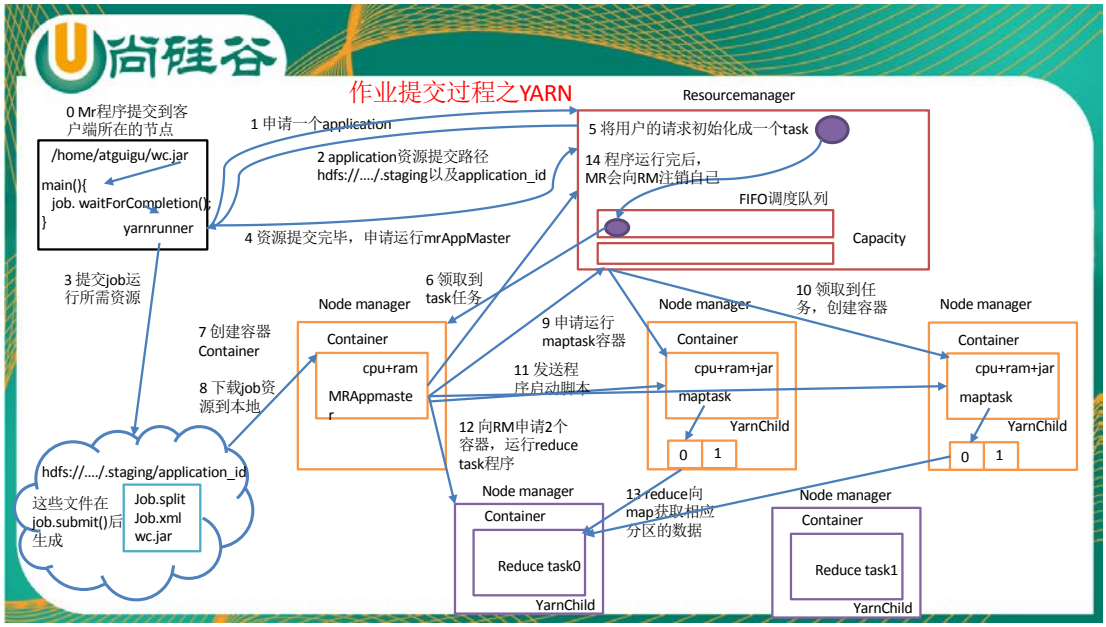

作业提交全过程详解

（1）作业提交

第 0 步：client 调用 job.waitForCompletion 方法，向整个集群提交 MapReduce 作业。

第 1 步：client 向 RM 申请一个作业 id。

第 2 步：RM 给 client 返回该 job 资源的提交路径和作业 id。

第 3 步：client 提交 jar 包、切片信息和配置文件到指定的资源提交路径。

第 4 步：client 提交完资源后，向 RM 申请运行 MrAppMaster。

（2）作业初始化

第 5 步：当 RM 收到 client 的请求后，将该 job 添加到容量调度器中。

第 6 步：某一个空闲的 NM 领取到该 job。

第 7 步：该 NM 创建 Container，并产生 MRAppmaster。

第 8 步：下载 client 提交的资源到本地。

（3）任务分配

第 9 步：MrAppMaster 向 RM 申请运行多个 maptask 任务资源。

第 10 步：RM 将运行 maptask 任务分配给另外两个 NodeManager，另两个 NodeManager 分别领取任务并创建容器。

（4）任务运行

第 11 步：MR 向两个接收到任务的 NodeManager 发送程序启动脚本，这两个 NodeManager 分别启动 maptask，maptask 对数据分区排序。

第 12 步：MrAppMaster 等待所有 maptask 运行完毕后，向 RM 申请容器，运行 reduce task。

第 13 步：reduce task 向 maptask 获取相应分区的数据。

第 14 步：程序运行完毕后，MR 会向 RM 申请注销自己。

（5）进度和状态更新

YARN 中的任务将其进度和状态(包括 counter)返回给应用管理器，客户端每秒(通过 mapreduce.client.progressmonitor.pollinterval 设置)向应用管理器请求进度更新，展示给用户。

（6）作业完成

除了向应用管理器请求作业进度外，客户端每 5 分钟都会通过调用 waitForCompletion()来检查作业是否完成。时间间隔可以通过 mapreduce.client.completion.pollinterval 来设置。作业完成之后，应用管理器和 container 会清理工作状态。作业的信息会被作业历史服务器存储以备之后用户核查。

2）作业提交过程之 MapReduce

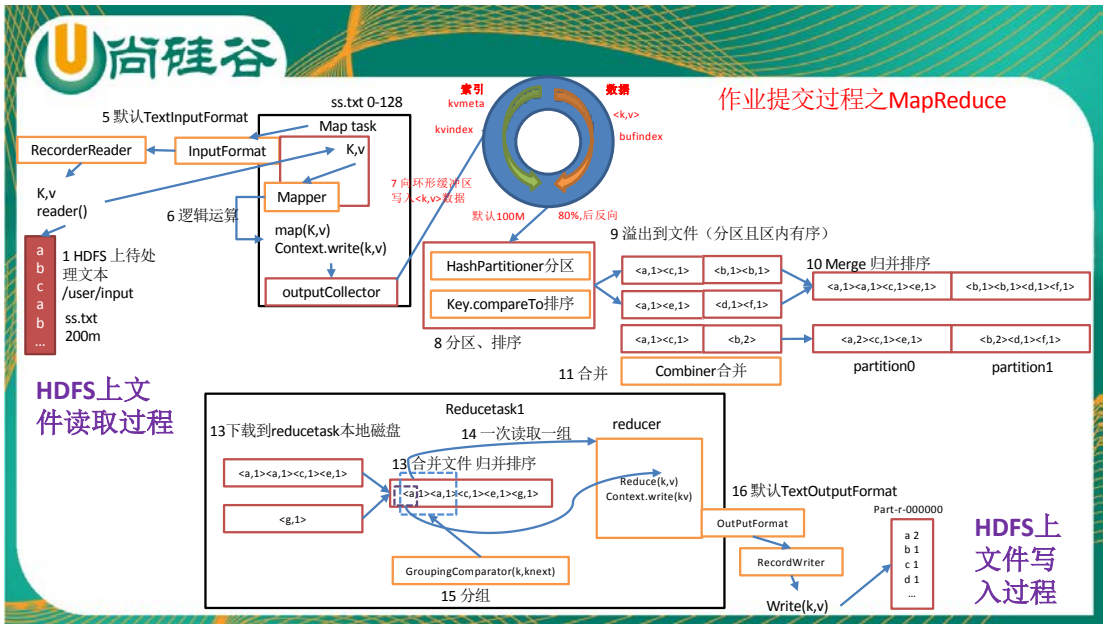

5.5 资源调度器

目前，Hadoop 作业调度器主要有三种：FIFO、Capacity Scheduler 和 Fair Scheduler。Hadoop2.7.2 默认的资源调度器是 Capacity Scheduler。

具体设置详见：yarn-default.xml 文件

```
<property>
    <description>The class to use as the resource scheduler.</description>
```

```
        <name>yarn.resourcemanager.scheduler.class</name>
<value>org.apache.hadoop.yarn.server.resourcemanager.scheduler.capacity.CapacityScheduler</value>
</property>
```

1）先进先出调度器（FIFO）

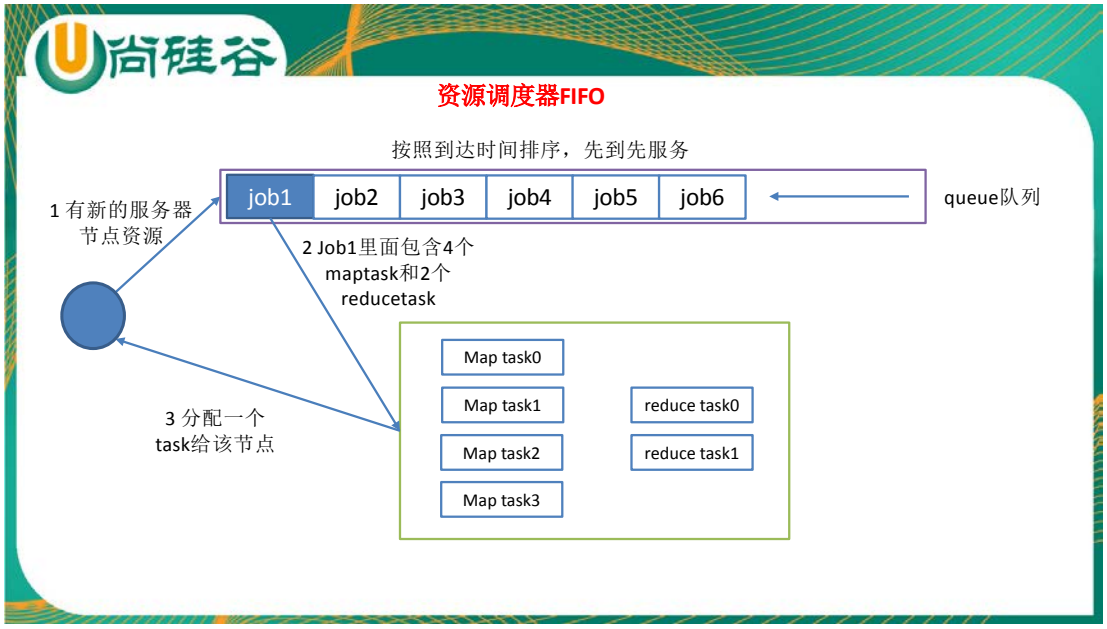

2）容量调度器（Capacity Scheduler）

3）公平调度器（Fair Scheduler）

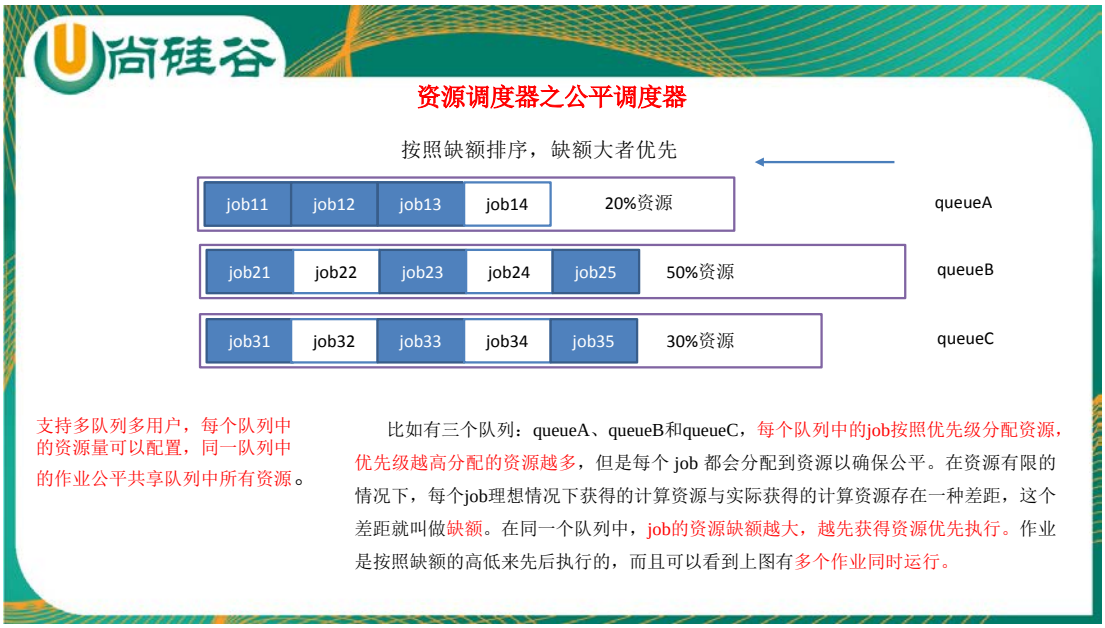

5.6 任务的推测执行

1）作业完成时间取决于最慢的任务完成时间

一个作业由若干个 Map 任务和 Reduce 任务构成。因硬件老化、软件 Bug 等，某些任务可能运行非常慢。

典型案例：系统中有 99%的 Map 任务都完成了，只有少数几个 Map 老是进度很慢，完不成，怎么办？

2）推测执行机制：

发现拖后腿的任务，比如某个任务运行速度远慢于任务平均速度。为拖后腿任务启动一个备份任务，同时运行。谁先运行完，则采用谁的结果。

3）执行推测任务的前提条件

（1）每个 task 只能有一个备份任务；

（2）当前 job 已完成的 task 必须不小于 0.05（5%）

（3）开启推测执行参数设置。Hadoop2.7.2 mapred-site.xml 文件中默认是打开的。

```
<property>
  <name>mapreduce.map.speculative</name>
  <value>true</value>
  <description>If true, then multiple instances of some map tasks may be executed in parallel.</description>
</property>

<property>
  <name>mapreduce.reduce.speculative</name>
```

```
    <value>true</value>
    <description>If true, then multiple instances of some reduce tasks
                 may be executed in parallel.</description>
</property>
```

4）不能启用推测执行机制情况

（1）任务间存在严重的负载倾斜；

（2）特殊任务，比如任务向数据库中写数据。

5）算法原理